

求职方向: Agent Harness 工程师

Agent Runtime · Context Engineering · Agent Evaluation

工作经历

Epiminds (斯德哥尔摩)

2026.02 – 2026.05

Founding AI 工程师

- 构建企业级多智能体营销平台, 设计并实现 20+ 个专家 Agent, 覆盖受众分析、广告创意、优化与跨平台投放; 基于 Vercel AI SDK 实现模型调用、结构化输出与流式交互, 与 Google、Meta Ads 等平台 API 集成。
- 基于 Temporal 构建长生命周期 Agent Workflow, 将多步骤推理、工具调用、人工审批与外部 API 操作编排为可持久化执行流程, 支持状态恢复、失败重试与故障恢复; 负责 React、Express、PostgreSQL 与 Redis 核心系统开发并部署于 GCP, 服务 100+ 企业日活用户。
- 设计并落地用户反馈驱动的 Agent 持续优化闭环: 通过产品侧点赞 / 点踩收集低摩擦用户反馈, 每周对生产 Trace 进行离线分析, 从端到端回答进一步归因至 Agent Routing、Tool Call、Context 等环节; 结合用户历史 Profile 与跨 Agent 交互进行归因, 而非孤立评估单条 Trace, 以识别长期偏好与系统性失败模式。
- 参考 SkillOpt 思路迭代 Few-shot、Prompt / Skill 与路由策略; 基于脱敏生产数据构建分层回归测试集, 在 Harness / 模型更新后执行端到端与工具级测试, 联合评估回答质量、延迟与执行步数, 检测行为退化。

Mozart AI (伦敦 / 巴黎)

2025.10 – 2026.01

AI 开发工程师

- 从 0 到 1 交付 AI Music Video 服务, 负责架构设计、多模态生成流水线与生产部署; 将歌词和音乐特征转化为 LLM 生成的叙事、视觉风格与分镜, 协调下游图像与视频模型, 并实现音乐节拍对齐; 协作构建长耗时生成任务的异步执行机制并部署于 GCP, 服务约 700 DAU。
- 参与歌词生成小模型后训练, 围绕团队共同维护的歌曲样本进行脱敏与重写, 从歌词内容、结构、韵脚等维度设计质量标准, 并结合 LLM Judge 与声学特征分析构建小规模、高质量训练与偏好数据集。
- 构建 RLAIIF-style Preference Data Pipeline: 首先通过 SFT 使模型学习作曲结构框架与分段能力; 随后采用 DPO 学习团队定义的高质量歌词偏好, 保持结构正确性的同时优化 Creative Writing 能力。

Misogi Labs (巴黎)

2025.05 – 2025.09

AI 开发工程师

- 面向候选分子筛选场景, 集成 MCP、LangGraph 与生成式模型, 构建包含分子特性预测与 Tool Calling 的多智能体工作流, 并负责端到端流程编排及计算化学场景验证。

法国兴业银行 (巴黎)

2024.04 – 2024.10

AI 开发工程师, 实习

- 主导开发跨部门 Agentic RAG 知识问答系统, 使用 LangChain 和 ElasticSearch 构建文档检索, 接入 4,000+ 份企业内部文档; 同期与团队交付 CI/CD 部署自动化系统及生产事故检测助手。

精选项目

Codex Privacy HUD

2026.09 – 至今

OpenAI Privacy Hackathon - Paris 冠军 · GitHub 累积 100+ Stars

- 开发面向 OpenAI Codex 的运行时隐私与审计插件, 集成本地 openai/privacy-filter; 基于 Lifecycle Hooks 捕获用户输入、工具结果、子智能体及工具调用参数等已接入边界中的敏感信息流。
- 构建事件驱动的 Session Disclosure Ledger, 区分本地检测、已披露与已阻止事件; 将 Privacy HUD 集成至独立构建的 Codex CLI 状态栏, 通过实时状态、会话审计及逐事件详情展示 Agent 执行过程中敏感数据的流转状态; 获奖后持续迭代, 目前由本人独立维护, GitHub 累积 100+ Stars。

链接: <https://github.com/inin-zou/codex-privacy-hud>

技术项目

Clio：全双工语音 Agent2026

Big Berlin Hack · Inca Track 冠军

- 基于 **PersonaPlex 7B** 构建面向保险理赔场景的全双工 Speech-to-Speech Agent，通过 **Twilio / LiveKit** 接入真实电话链路；将实时音频执行与异步业务控制分离，使控制通道仅处理结构化指令与转录事件。
- 将信息抽取与业务推理移出实时语音 Hot Path，通过规则式 **Intervention Gate** 与逐 Token 注入控制复述确认、缺失字段追问及结束检查；针对高风险字段加入用户原话锚定校验，过滤缺乏来源依据的状态更新。
- 将模型与 LiveKit Agent 部署于 A100，结合会话状态恢复降低启动开销；对电话链路、WebRTC、GPU Inference 进行 Latency Profiling，项目记录的端到端 **Round-trip Latency** 约为 **450–650 ms**。

链接: <https://github.com/inin-zou/Clio>

KernelGen 多后端 AI 算子优化2026.05

GOSIM KernelGen 2026 · Sparse Attention 赛道第 1 名

- 基于 **Triton / FlagTree** 优化动态稀疏注意力与 DeepSeek mHC，为 Ascend、天数智芯、海光、摩尔线程与沐曦五类 AI 加速器设计后端分派及兼容执行路径。
- 针对 Top-k Gather Sparse Attention，结合在线 Softmax、BF16 计算路径、FP32 回退与 V 分块策略优化访存及寄存器压力；相较 PyTorch 参考实现，五后端平均加速 **1.97 倍**。
- 针对 mHC 使用运行时 Sinkhorn 循环、自动调参与按输入规模分派，在五后端取得平均 **71.85 倍加速**，摩尔线程后端达到 **201.32 倍**；建立参考实现、数值正确性测试与性能 Benchmark。

链接: <https://github.com/inin-zou/kernelgen-challenge>

技能与荣誉

智能体开发：MCP、RAG；Vercel AI SDK、LangGraph、LangChain

监控与可观测性：Langfuse、Sentry、Prometheus、Grafana、PostHog

模型训练与推理：SFT (LoRA)、RL (DPO、GRPO)；vLLM、Triton、PyTorch

编程语言：Python、TypeScript、SQL

后端与系统工程：Prisma、Node.js、Express、PostgreSQL、Redis、Temporal、Docker、GitHub Actions、GCP

前端开发：React、Next.js、Vite、tailwind CSS

竞赛荣誉：14 次国际 AI Hackathon 获奖，包括 OpenAI Hackathon 冠军、Lovable x Google DeepMind 黑客松季军

语言能力：法语 (DALF C1)、英语 (IELTS 7.0)

教育经历

巴黎文理研究大学 – PSL (Université Paris Dauphine – PSL)2023.09 – 2024.12

计算机科学 | 硕士学位

QS World University Rankings 2025: #24 | 年级排名第 10

巴黎萨克雷大学 (Université Paris-Saclay)2022.09 – 2023.08

计算机科学 | 硕士一年级

QS World University Rankings 2025: #73 | GPA: 14.41/20 | 年级排名第 3

图卢兹第一大学 (Université Toulouse 1 Capitole)2019.09 – 2022.06

计算机、经济管理学 | 学士学位

经济学与计量经济学 QS Rankings: #71 | 年级排名第 5